

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE GOIÁS (PUC GO)
ESCOLA POLITÉCNICA E DE ARTES
CIÊNCIA DE DADOS E IA
DISCIPLINA: VISÃO COMPUTACIONAL - TURMA: 2026.2-CDI1021

CAIO HENRIQUE LIMA DE ANDRADE

2024.101.37.0025-0

ALISSON LEONARDO AMARAL DO NASCIMENTO

2024.101.37.0017-0

FERNANDA ANDRADE

2024.101.37.0004-8

VITOR MANOEL

2024.101.37.0030-7

Sistema Inteligente de Detecção e Classificação de Placas de Trânsito

Relatório Técnico Parcial · 1ª Etapa (N1)

Goiânia, Goiás

2026

SUMÁRIO

1. CONTEXTUALIZAÇÃO DO PROBLEMA

1.1. Relevância prática

2. DESCRIÇÃO DO DATASET

2.1. Critérios de seleção

2.2. Correção do esticamento da base

3. ARQUITETURA DA SOLUÇÃO

4. PIPELINE IMPLEMENTADO

4.1. Justificativa de cada parâmetro

5. RESULTADOS PARCIAIS

5.1. Evidências visuais antes e depois

6. LIMITAÇÕES IDENTIFICADAS

7. PRÓXIMOS PASSOS

8. REPOSITÓRIO E REPRODUTIBILIDADE

9. REFERÊNCIAS

1. CONTEXTUALIZAÇÃO DO PROBLEMA

A sinalização vertical é o principal canal de comunicação entre a via e o condutor. É por meio dela que se informa o limite de velocidade, a preferência em um cruzamento, a curva acentuada adiante e a proximidade de uma escola. Quando uma placa está ausente, desbotada, torta ou encoberta por vegetação, a informação deixa de chegar a quem dirige, e o risco recai sobre quem trafega.

O Código de Trânsito Brasileiro atribui ao órgão ou entidade com circunscrição sobre a via a responsabilidade pela implantação e pela manutenção da sinalização. Cumprir essa obrigação exige saber o que existe e em que estado está, e hoje esse levantamento é feito por vistoria manual em campo, percorrendo a malha trecho a trecho. O processo é lento, amostral e difícil de auditar: em uma malha urbana com milhares de quilômetros, o inventário fica desatualizado antes de terminar.

A dificuldade técnica do problema não está em identificar o significado da placa, e sim na etapa anterior: isolá-la de uma cena visualmente saturada, em que ela concorre com fachadas, vegetação, veículos e sinalização publicitária, sob iluminação irregular, contraluz, sombra projetada, desbotamento da película refletiva e oclusão parcial.

Esta 1ª Etapa resolve a etapa anterior com Processamento Digital de Imagens clássico, sem aprendizado de máquina. Dada uma imagem de via, o sistema produz uma máscara binária das placas e dela extrai contagem, área, centroide, caixa envolvente e classe geométrica, além do recorte normalizado da região de interesse que alimentará o modelo de IA da 2ª Etapa.

1.1. Relevância prática

A aplicação direta é o inventário viário assistido. Um veículo comum, com uma câmera fixada no para-brisa, percorre a via em velocidade normal de tráfego e grava. O processamento posterior localiza as placas, conta quantas são e registra posição e dimensão de cada uma. O trabalho humano deixa de ser percorrer a malha inteira e passa a ser conferir e validar o que o sistema apontou.

Três ganhos decorrem disso. O primeiro é a cobertura: a mesma equipe cobre mais quilômetros por dia, porque não precisa parar a cada placa. O segundo é a periodicidade: repetir o trajeto passa a custar o tempo de dirigir, o que viabiliza revisões frequentes em vez de campanhas esporádicas. O terceiro é a auditabilidade: cada registro fica associado a uma imagem datada, de modo que a decisão de trocar ou manter uma placa pode ser justificada com evidência.

O mesmo pipeline serve a outros usos que compartilham a etapa de localização, como apoio a sistemas de assistência ao condutor e auditoria de projetos de sinalização recém implantados.

2. DESCRIÇÃO DO DATASET

A base utilizada é Roboflow Universe / caios-workspace-01wh5/placas-de-transito-br-wq5tp versao 1, com licença Public Domain, disponível em <https://universe.roboflow.com/caios-workspace-01wh5/placas-de-transito-br-wq5tp/dataset/1>. Trata-se de uma cópia em resolução nativa da base original *stefano-tommasini-coelho-euf67/placas-de-transito-br*, publicada no Roboflow Universe. São quadros de câmera veicular em rodovias brasileiras.

Item	Valor
Imagens	2.963
Objetos anotados	2.305
Classes	68, nomeadas pelos códigos do CONTRAN
Dimensão mediana	1.270×636 px
Escala do objeto	lado equivalente mediano de 37,5 px; percentil 10 em 19,2 px
Formato de anotação	Caixa delimitadora em YOLO (classe, cx, cy, largura, altura)
Divisão adotada	1.039 imagens de ajuste e 934 de validação, em 179 trechos de gravação disjuntos

2.1. Critérios de seleção

A base foi escolhida por três critérios. Primeiro, ser de sinalização vertical brasileira, já que cor, forma e proporção das placas são definidas por resolução do CONTRAN, o que permite fundamentar cada parâmetro do pipeline em especificação verificável em vez de tentativa e erro. Segundo, conter cenas completas de via, e não recortes centralizados na placa, que tornariam a segmentação trivial e sem relação com o uso real. Terceiro, ter anotação em caixa delimitadora, necessária para medir precisão e recall.

Duas bases candidatas foram descartadas nesse processo. Uma delas era composta de recortes próximos da placa, com o objeto ocupando a maior parte do quadro. A outra continha imagens sintéticas, com placas recortadas e coladas sobre fotografias de contexto não viário, identificadas pelo padrão dos nomes de arquivo e confirmadas por inspeção visual.

2.2. Correção do esticamento da base

Todas as nove versões publicadas da base original aplicam o pré-processamento *Resize to 640×640 (Stretch)*. As imagens de origem medem cerca de 1.270×636 px, de

modo que o redimensionamento comprime a largura pela metade e mantém a altura: a imagem chega espremida em aproximadamente 2:1. Uma placa circular vira uma elipse deitada, e os descritores de forma passam a descrever a distorção, e não o objeto.

A base foi então clonada para o espaço de trabalho da equipe e reexportada apenas com Auto-Orient, sem redimensionamento. As imagens e as anotações são as mesmas, apenas reescaladas pelo próprio Roboflow. O efeito foi medido na mesma amostra de validação, sem alterar nenhuma linha do pipeline.

Métrica (validação retida)	Base esticada	Base nativa
Precisão	0,137	0,236
Recall	0,157	0,175
F1	0,146	0,201
Falsos positivos	278	159
Objetos com forma ambígua	89,4%	79,8%

A precisão subiu 72% e os falsos positivos caíram 43%. O ganho não vem de um pipeline melhor, e sim de deixar de processar uma imagem deformada. O registro fica como alerta para a 2ª Etapa: treinar um detector sobre a base esticada teria o mesmo problema, sem nenhum aviso.

3. ARQUITETURA DA SOLUÇÃO

O diagrama apresenta o fluxo da imagem de entrada até a saída, com a faixa tracejada indicando onde o modelo de IA entra na 2ª Etapa. A fronteira entre as duas etapas é a ROI normalizada: esta etapa entrega o recorte da região de interesse com seus descritores geométricos, e é esse recorte que a rede neural consumirá.

O pipeline clássico não é descartado na etapa seguinte. Ele permanece em três papéis: a correção de iluminação como pré-processamento do detector treinado, o filtro por área como pós-processamento das caixas propostas, e a contagem clássica como linha de base comparativa.




Figura 1 - Arquitetura da solução. O bloco tracejado corresponde à 2ª Etapa.

4. PIPELINE IMPLEMENTADO

O pipeline é composto por funções independentes, cada uma responsável por uma etapa, encadeadas por um orquestrador. A ordem não é arbitrária: suavizar antes de limiarizar evita que o ruído de alta frequência desloque o limiar; corrigir a iluminação antes de converter para HSV preserva a matiz, que é o atributo em que a segmentação se apoia; e os contornos saem sempre da máscara morfológica, nunca do Canny, porque uma borda de um pixel tem dois lados e produziria dois contornos por objeto, duplicando a contagem.

Etapa	Parâmetro adotado	Justificativa
1. Entrada	Largura de 1.248 px	Resolução nativa da base. Reduzir encolheria objetos que já são pequenos; padronizar torna os parâmetros em pixel comparáveis entre imagens
2. Iluminação	CLAHE, clip 2,0, grade 8×8	Aplicado ao canal L* do LAB. Equalizar os três canais RGB mudaria a proporção entre eles e deslocaria a matiz
3. Suavização	Gaussiano 3×3	$\text{ímpar}(0,10 \times 19,2) = 3$. O borrão precisa ser mais estreito que a orla da menor placa detectável
4. Evidência de cor	vermelho (H 8, s_min 100); amarelo (H 16, s_min 120)	Centro e largura das faixas medidos nos pixels das caixas anotadas; portas de saturação escolhidas por F1
5. Limiarização	global, corte 96	Os quatro métodos testados empatam dentro da margem de ruído; o desempate declarado é pelo método mais simples
6. Morfologia	Abertura 3×3, fechamento 9×9	$\text{ímpar}(0,10 \times 19,2) = 3$ e $\text{ímpar}(0,25 \times 37,5) = 9$. O fechamento precisa vencer a espessura do miolo branco da placa
7. Contornos	findContours com RETR_EXTERNAL	Apenas contornos externos, o que evita contar o miolo da placa como segundo objeto
8. Filtros de forma	Área de 479 a 12.887 px ² ; razão de aspecto, extensão e solidez	Quantis 0,40 e 0,95 da distribuição de áreas anotadas

4.1. Justificativa de cada parâmetro

Nenhum valor foi escolhido por tentativa e erro. Os parâmetros têm três origens, e cada uma tem um método próprio de determinação.

Origem	Parâmetros	Método
Escala do objeto	Kernels de suavização, abertura e fechamento	Medição do lado equivalente das caixas anotadas do lado de ajuste. São consequência geométrica do tamanho da placa e não dependem de desempenho

Origem	Parâmetros	Método
Histograma	Faixas de matiz e portas de saturação	Matiz dominante medida no núcleo das caixas anotadas. Para cada porta candidata, mede-se que fração de pixel de placa e de fundo sobrevive
Busca em grade	Método de limiarização, corte, área mínima e máxima	Quatro estágios de busca por coordenadas sobre a amostra de ajuste, com maior F1 em IoU maior ou igual a 0,30 como critério

Duas regras de desempate foram declaradas antes de executar a busca, porque diferenças menores que 0,005 de F1 cabem no ruído de uma amostra de 250 imagens. Primeira: uma faixa de cor só permanece no pipeline se superar o seu descarte por mais que essa margem. Segunda: entre métodos de limiarização empatados nessa margem, permanece o mais simples. A primeira regra alterou o resultado, removendo a faixa azul, que capturava céu e quase nenhuma placa.




Figura 2 - Histogramas por canal (RGB, tons de cinza e HSV), antes e depois do CLAHE.




Figura 3 - Busca em grade: piso de área, teto de área e comparação entre os métodos de limiarização.

5. RESULTADOS PARCIAIS

A avaliação usa 250 imagens de validação, sorteadas entre trechos de gravação disjuntos dos de ajuste. Como a base é composta de quadros de câmera veicular capturados a poucos segundos de distância, uma divisão por imagem faria a mesma placa aparecer nos dois lados. A divisão por trecho garante que o quadro de validação mais próximo de um de ajuste esteja a 31 segundos. Nenhuma imagem avaliada participou da escolha de qualquer parâmetro.

Métrica	Valor
Precisão	0,236
Recall	0,175
F1	0,201
F1 na amostra de ajuste	0,193
Objetos anotados / detectados	280 / 208
Erro absoluto médio de contagem	0,87 objeto por imagem
Limiar T de Otsu (diagnóstico)	recalculado por imagem: média 80,1, de 37 a 138

O erro de contagem precisa de referência antes de ser interpretado. Das 250 imagens avaliadas, 226 têm exatamente uma placa anotada, de modo que responder sempre 'uma placa' erra 0,12 contra 0,87 do pipeline. Nesta base, portanto, o erro de contagem não avalia o sistema, e a leitura que vale é a de detecção.

O desempenho não é alto, e isso é informação, não fracasso. Um detector puramente cromático é a linha de base contra a qual o modelo treinado da 2ª Etapa será comparado, e o valor desse número está em existir, ser reproduzível e ter sido obtido com o mesmo protocolo que será usado depois.

5.1. Evidências visuais antes e depois

As imagens abaixo são sorteadas com semente fixa entre as de validação, sem seleção manual dos casos favoráveis. Cada painel percorre as seis etapas do pipeline, exibe o resultado do Canny (que não alimenta a contagem) e termina com as detecções sobre a imagem de entrada.

[1/6] captura_2023-10-09_13-51-24_png.rf.786ff49d69067866b2bf79da28ce2659.jpg · limiar aplicado: 96 · contornos brutos: 33 → aceitos: 1




Figura 4 - Etapas do pipeline sobre uma imagem de validação.

[2/6] captura_2023-10-02_15-19-36_png.rf.69fc7f5e7d3c3fb83a1353a2bb2b82e5.jpg · limiar aplicado: 96 · contornos brutos: 164 → aceitos: 4




Figura 5 - Etapas do pipeline sobre uma imagem de validação.

[3/6] captura_2023-09-28_16-03-07_png.rf.a94d89c6cc113bc7cb41edb54150672b.jpg · limiar aplicado: 96 · contornos brutos: 164 → aceitos: 2




Figura 6 - Etapas do pipeline sobre uma imagem de validação.

6. LIMITAÇÕES IDENTIFICADAS

Anotação esparsa da base. São 2.305 objetos anotados em cerca de 1.973 imagens, além de 990 imagens sem anotação alguma. As cenas costumam conter mais placas visíveis do que anotadas, e cada detecção correta de uma placa não anotada entra na conta como falso positivo. A precisão de 0,236 é, portanto, um piso, e não uma medida limpa do pipeline.

Falsos positivos de mesma cromaticidade. Lanterna traseira, veículo vermelho, toldo, solo exposto e grama seca compartilham matiz e saturação com as placas. Os filtros de forma removem parte deles, mas um objeto aproximadamente convexo e de proporção compatível é indistinguível por cor e geometria.

Placas pequenas são o teto do recall. Um décimo das placas anotadas tem menos de 19,2 px de lado equivalente, mesmo na resolução nativa. Foi por isso que a busca elevou o piso de área: abaixo dele, o ruído cromático rende mais do que a placa.

Círculo e octógono sob perspectiva. Nenhum descritor clássico separa as duas formas em visada oblíqua, porque a projeção achata ambas em elipses de razão equivalente. O código marca esses casos como forma ambígua em vez de arbitrar uma classe.

Corte fixo não é transferível. O método adotado usa um corte único, calibrado nesta base. Com outra câmera e outra condição de iluminação, é o primeiro valor a recalibrar.

O sistema não identifica o significado da placa. O pipeline entrega forma e posição, não a categoria normativa. Essa é, por definição, a tarefa da 2ª Etapa.

7. PRÓXIMOS PASSOS

A 2ª Etapa substitui a decisão baseada em cor e forma por um detector treinado, capaz de aprender contexto e textura. O ganho esperado concentra-se nos falsos positivos cromáticos e nas placas desbotadas, que são as duas maiores fontes de erro medidas nesta etapa. As anotações em código do CONTRAN já disponíveis na base permitem treinar detecção e classificação em um único modelo.

Dois limites identificados aqui permanecem e precisam de tratamento explícito na etapa seguinte. O primeiro é a escala: um décimo das placas tem menos de 19 px de lado, o que exige treinar com entrada em resolução maior ou processar a imagem em recortes. O segundo é a anotação esparsa, que pune o modelo por acertar placas não anotadas; uma passada de anotação sobre o subconjunto usado na avaliação melhoraria a confiabilidade da

métrica.

A incorporação de imagens capturadas pela própria equipe também está prevista, e servirá para verificar a transferência do sistema para outra câmera e outra condição de iluminação.

8. REPOSITÓRIO E REPRODUTIBILIDADE

O código-fonte, o notebook executável, as figuras e o registro completo dos parâmetros estão em <https://github.com/CaioHenri99/aed-visao-placas-transito>. O notebook executa de ponta a ponta no Google Colab e em ambiente local, e todos os parâmetros são recalculados a partir do próprio dataset, o que torna a execução reproduzível. A divisão de tarefas entre os integrantes está documentada no README do repositório.

A execução que originou os números deste relatório foi realizada em 22/09/2026, às 16:49, com semente 42, OpenCV 5.0.0 e Python 3.14.4.

9. REFERÊNCIAS

BRASIL. Lei nº 9.503, de 23 de setembro de 1997. Institui o Código de Trânsito Brasileiro. Brasília, 1997.

CONSELHO NACIONAL DE TRÂNSITO (CONTRAN). Manual Brasileiro de Sinalização de Trânsito. Volume I - Sinalização Vertical de Regulamentação. Brasília: CONTRAN.

CONSELHO NACIONAL DE TRÂNSITO (CONTRAN). Resolução nº 160, de 22 de abril de 2004. Aprova o Anexo II do Código de Trânsito Brasileiro. Brasília, 2004.

BRADSKI, G.; KAEHLER, A. Learning OpenCV: Computer Vision with the OpenCV Library. Sebastopol: O'Reilly Media, 2008.

GONZALEZ, R. C.; WOODS, R. E. Digital Image Processing. 4. ed. Nova York: Pearson, 2018.

OTSU, N. A Threshold Selection Method from Gray-Level Histograms. IEEE Transactions on Systems, Man, and Cybernetics, v. 9, n. 1, p. 62-66, 1979.

SUZUKI, S.; ABE, K. Topological Structural Analysis of Digitized Binary Images by Border Following. Computer Vision, Graphics, and Image Processing, v. 30, n. 1, p. 32-46, 1985.